

AlexNet

0. Abstract, 2. The Dataset

1. 0.1% : ImageNet LSVRC-2010 의 1.200,000 / 1000 labels

20/2

2. 7% : top-1 error 37.5% (모델이 가장 확률이 높다고 예측하는
- 5 11% (클래스가 2개이거나 비슷)
(모델이 8개의 5%를 예측하는 클래스는

top5 15.3%

3. 구조: 6 층망원

4. 65% : 65%

Conv + maxpool : 5%

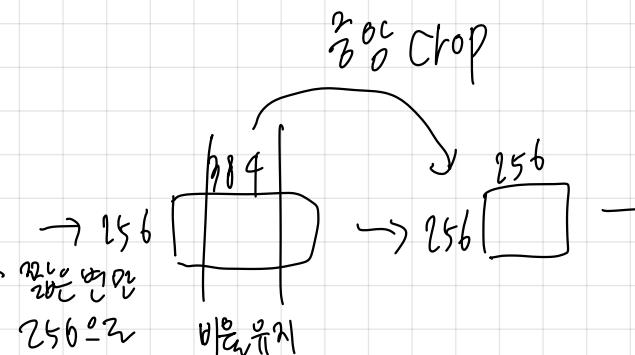
fc : 77% (dropout 1000-1000 softmax)

activation : ReLU

func

dropout

5. 0.1% : 256x256 \Rightarrow 400



→ Mean subtraction: 모든 이미지의 각 층별 평균 $(\bar{x}, \bar{y}, \bar{c})$ $\frac{1}{n} \sum_{i=1}^n x_i$ \Rightarrow "224x224"
($\bar{x}, \bar{y}, \bar{c}$ 는 각 층별 평균)

4.1

Data Augmentation

1. Introduction

1. 학습: ImageNet \downarrow \rightarrow 원본 이미지
2. 학습: ImageNet \uparrow

label-preserving augmentation: 224x224

→ 학습: 좋은 learning capacity X
but,

CNN: $H \times W$ 로 용량 미지 흡수할 가능성

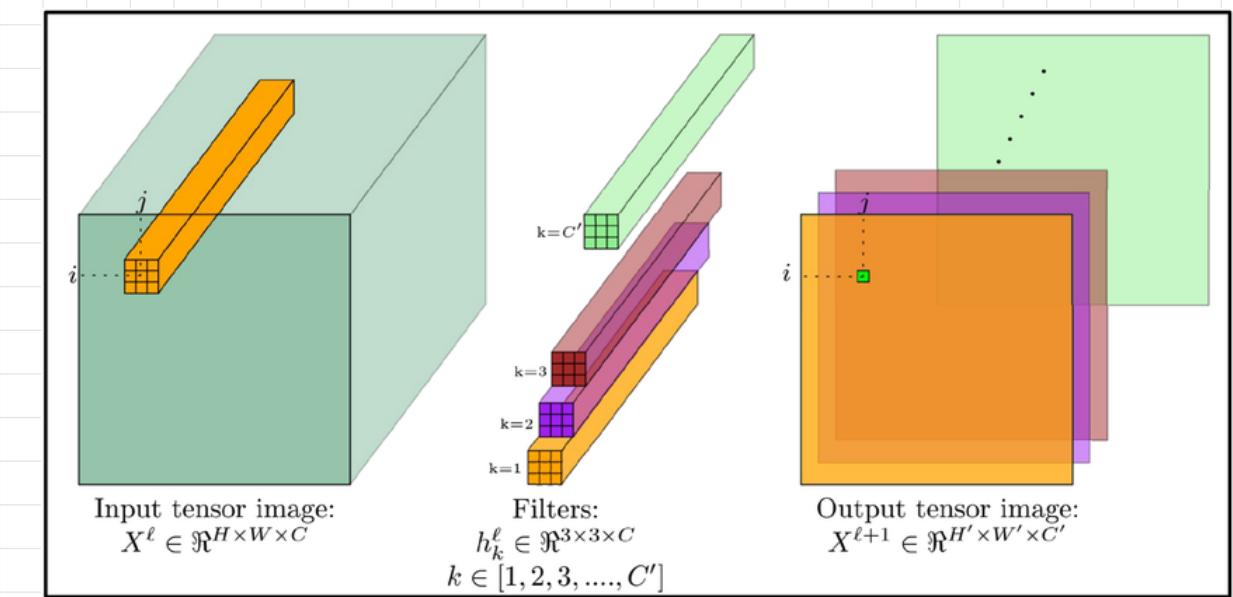
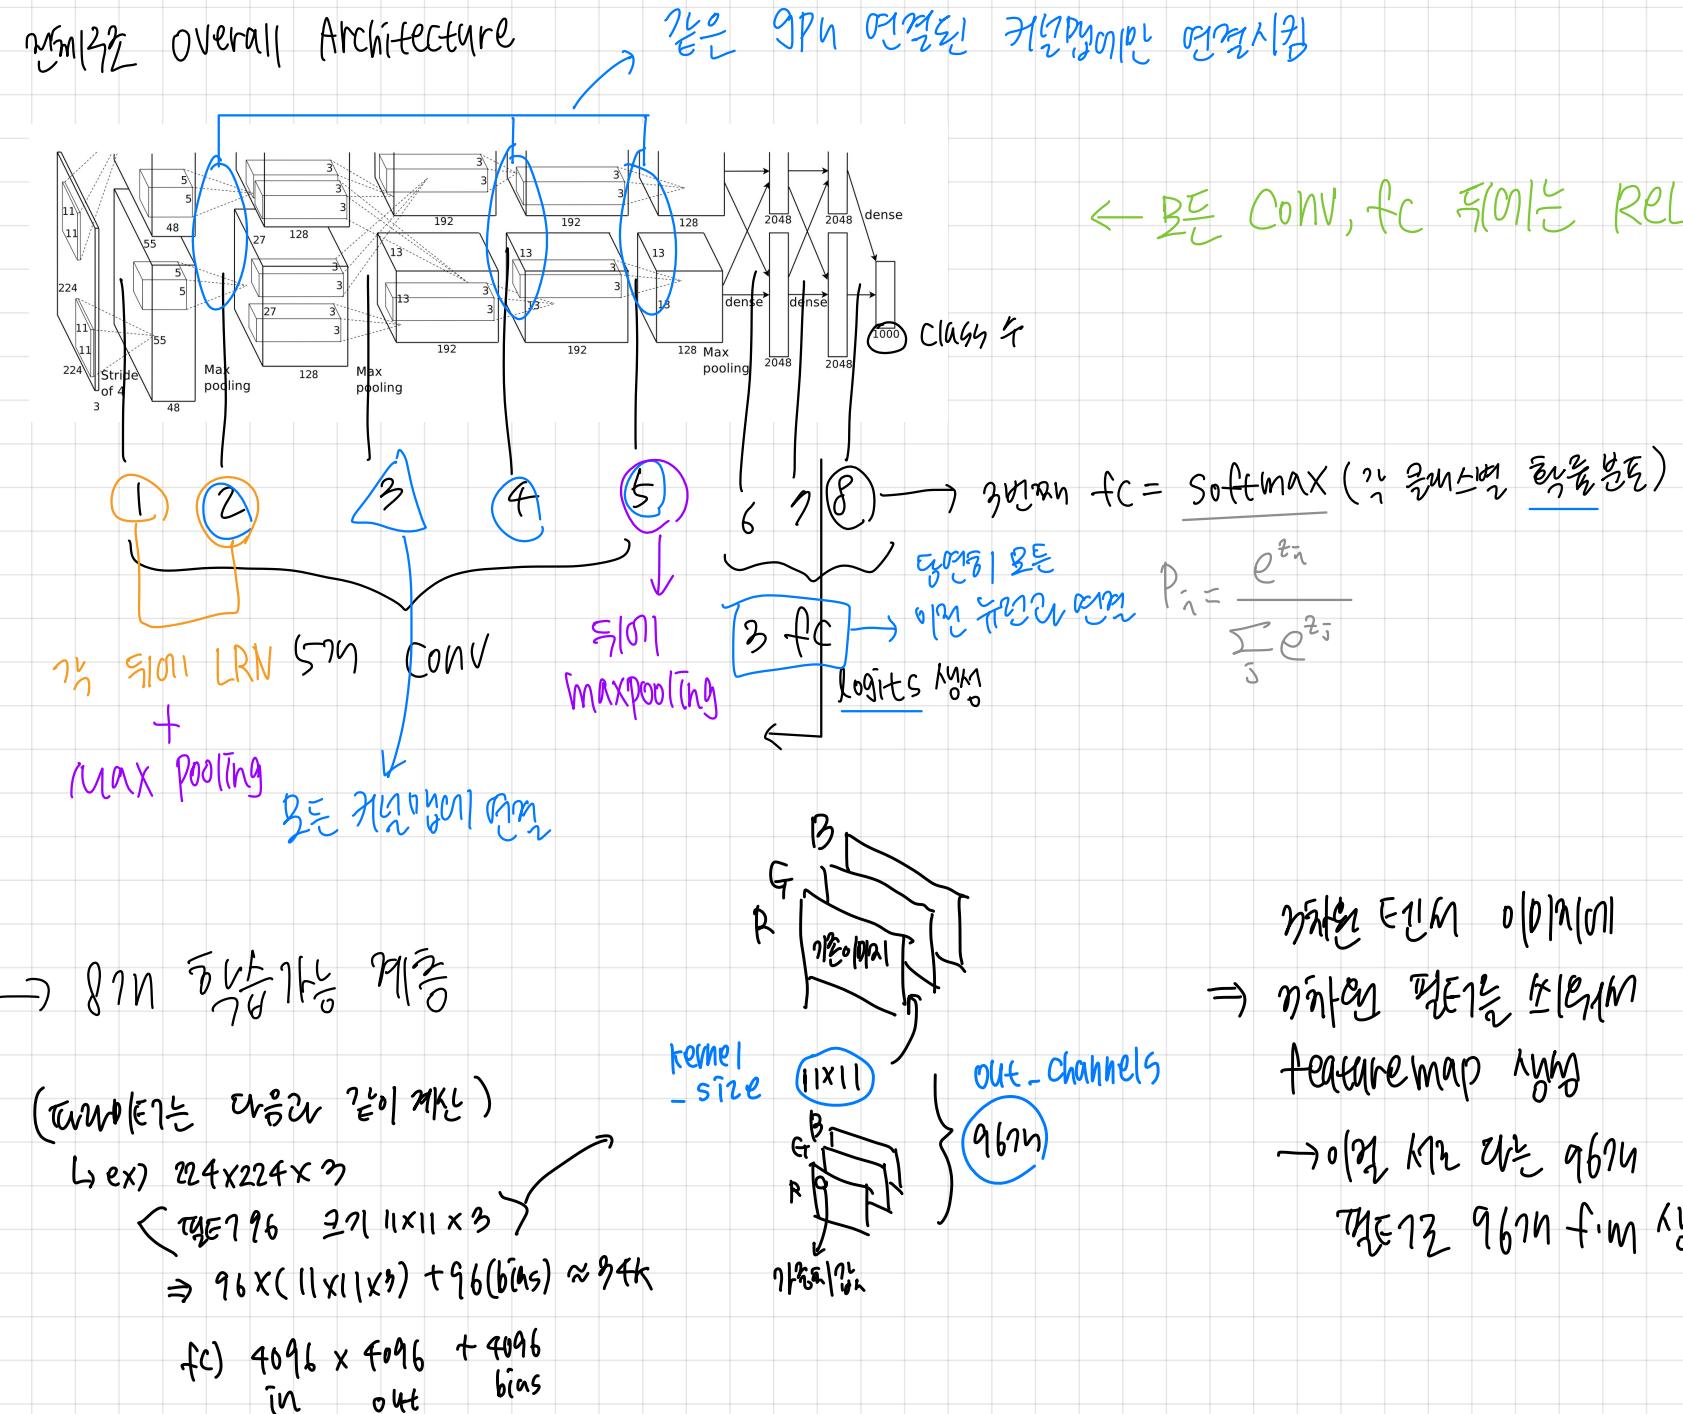
• 온바른 가정 (stationarity of statistics): 각 층은 위치가 따른 특성이 달라지지 X

• locality of pixel dependency: 같은 위치에 있는 픽셀들이 서로 영향을
끼칠 확률이 0이 X

→ 만일 fc의 위치가 전부 다不一样 수 ↓, 성능 ↑

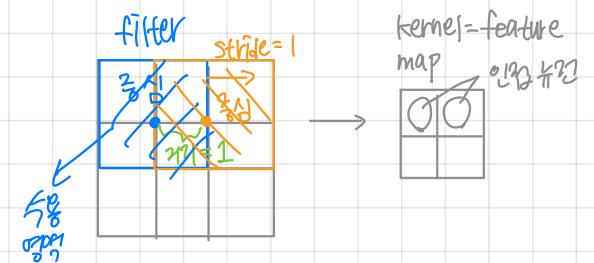
3. The Architecture

1. System Overall Architecture



→

계층별로서 이미지 뉴런간
각 수용 영역의 중심간 거리



총 712 차원

Layer	Img/ f. m	size	kernel_size	out_channels	stride	padding	
150528	Input	224x224x3					
254460	conv1	55x55x96	11x11x3	96	4	2	+LRN +ReLU
186624	max pooling	27x27x96	3x3x96		2		+ReLU
186624	conv2	27x27x256	5x5x96	256	1	2	+LRN +ReLU
64896	max pooling	13x13x256	3x3x256		2		+ReLU
64896	conv3	13x13x384	3x3x256	384	1	1	+ReLU
64896	conv4	13x13x384	3x3x384	384	1	1	+ReLU
43264	conv5	13x13x256	3x3x384	256	1	1	+ReLU
43264	max pooling	6x6x256	3x3x256		2		+ReLU

flatten $6 \times 6 \times 256 = 9216$

4096 fc1 $9216 \rightarrow 4096$ + dropout
4096 fc2 $4096 \rightarrow 4096$ + dropout
num_classes fc3 $4096 \rightarrow \text{num_classes}$

→ 총 712 차원 ; $224 \times 224 \times 3 = 150528$

2. ReLU (Rectified Linear Unit) : $\max(0, x)$

→ 정사각형 시 \tanh , sigmoid 등 흐르는 비선형은 속도 느림 // $\oplus |\tanh(x)|$ but, 계산량 증가 해결방법,
일정한 속도 느림은 X
(GPU)

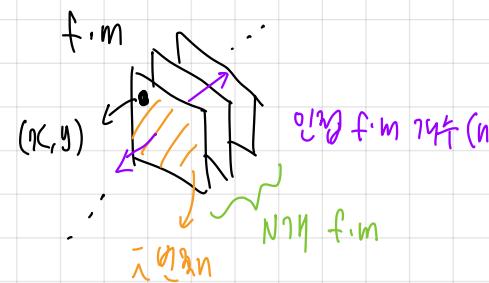
3. Local Response Normalization (지소 응답 정규화) : LRN // $\oplus LCN$ (깊은 모델 정규화)

→ ReLU는 흐르는지를 위한 기본적인 흐름 X (Positive only then 학습)

→ ReLU 외에 local normalization 같은 다른 방법도 T

→ $b_{x,y}^i = d_{x,y}^i \left(\Delta + \Delta \sum_{j=\max(0, i-k/2)}^{\min(N-1, i+n/2)} (a_{x,y}^j)^2 \right)^{-1/2}$
ReLU 후의 N개 f.m 중 1개만
f.m에서의 위치 (x, y)

\Rightarrow top 1 1.4% ↓
top 5 1.2% ↓



4. Overlapping Pooling (중첩 풀링)

→ Pooling : 중첩 풀링(커널 크기)의 원인 뉴런들이 다른 인접 뉴런들의 출력을共享,
= 같은 패턴에서 어떤 뉴런
→ 풀링이 연속하는 영역이 학습하기 어렵도록 stride와 $\frac{z(\text{원도우 크기})}{\text{Stride}} \times \frac{z(\text{원도우 크기})}{\text{한 번에 뉴는 크기}}$ (z by z)

→ 예: $\begin{matrix} 1 & 2 & 3 \\ 2 & 3 & 4 \\ 3 & 4 & 5 \end{matrix}$

$\hookrightarrow s=2, z=2$ (비중첩) 일 때와 풀링 크기 동일하되,
top 1 0.4% ↓
top 5 0.3% ↓
과적합 ↓

4. Reducing overfitting (과적합 감소)

① label-preserving transformation 27%]

1. translation + horizontal reflection

$256 \times 256 \downarrow$ \hookrightarrow transforms, Random Horizontal Flip(p) : 전체 흰면 데잍셋을 P 확률 만 수령 반전 (좌우반전)
 224×224 흰면 무작위 추출

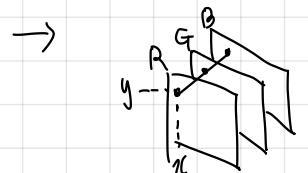
(transforms, RandomCrop(224))

→ test 시에 사용: 각 원본당 224x224 흰면 $\frac{5}{7}n$ + 각 좌우반전 \Rightarrow 각 흰면 $10n$ 흰면

$\frac{5}{7}n + \frac{2}{7}n$ \downarrow
각 흰면에 대처 softmax 후 평균

2. RGB 채널 강도 조정 \rightarrow top 1% 흐트

↳ 물체 정체성 (Identity)이 조정 강도와 상관이 있음을 발견



Input img

$$\Rightarrow I_{xy} = \begin{bmatrix} I_{xy}^R \\ I_{xy}^G \\ I_{xy}^B \end{bmatrix} \text{ 가 } 224 \times 224 \text{ 인 행렬 (1장 img)} \rightarrow N\text{th 차원 이미지} \\ \Rightarrow (50/176 \times N) \times 3 \text{ (2차원 행렬)}$$



$N\text{th}$: (제작 50/176 뒤에) 50/176개씩 이어붙임

↓ 공분산 행렬

1) “ RGB ” 채널별 행렬 M_R, M_G, M_B 구하고 각 채널 행렬들에서 배수하기 $\Rightarrow X$ 행렬

$$2) \frac{1}{N} \sum X^T \cdot X = [3 \times (50/176 \times N)] \times [(50/176 \times N) \times 3] = 3 \times 3 \text{ 공분산 행렬} = \Sigma$$

3) PCA 수행: P (2차원 EIG), λ (2차원)

↳ $\Sigma P = \lambda P$ 수행 ($\det(\Sigma - \lambda I) = 0$ 구하면 $\lambda_1, \lambda_2, \lambda_3$ 찾고 $\Sigma P = \lambda P$ 구하기)

↓

$[P_1 \ P_2 \ P_3] \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix}$ 의 값은 모든 각 픽셀의 차례로

$$\lambda = \frac{\text{가장 큰 차이를 뿐만 아니라 다른 차이도}}{\mu=0, \sigma=0.1}$$

② dropout: 순전파 시 일부 뉴런 끄기 (역전파도 영향이 사용X)

\rightarrow 1) 뉴런끼리 차이난 모든 뉴런, 뉴런 다른 그룹의 (끼끼) 네트워크 = 양상분 (단, 가중치는 같은 연결이거나 다른 네트워크에서 공유) / 2) 수령까지 빨라갈수록 차이

\rightarrow test: 모든 뉴런을 쓰되, 출발값에 $\times 0.5 \rightarrow$ 양상분의 (끼끼) 템포 흐트하기 위해

5. Details of learning

1. Optimizer: SGD

→ optim.SGD(model.parameters(), lr, momentum, weight_decay)

→ momentum: 0.9 / weight-decay: 0.0005

↳ "관성": GD의 가속

증사에서 진동하는 문제

해결하기 위한 이전 기울기의

이동 방향 기억해서 전환

기울기에서 더러운 업데이트

(이전 방향대로 업데이트)

↳ 과적합 막기 위한 Regularization (weight 가리는 것 막기)

: loss(y, \hat{y}) + $\lambda \sum_i w_i^2$ (loss 줄이는 것 목표니까)

(training errors 줄이듯)

⇒ 최종 weight update 규칙: $w_{i+1} = w_i + v_{i+1}$

$$= 0.9 \cdot v_i - 0.0005 \cdot \epsilon \cdot w_i - \epsilon \cdot \left\langle \frac{\partial L}{\partial w} \Big|_{w_i} \right\rangle_{D_i}$$

↳ i : iteration

v_i : momentum 변수

ϵ : lr

D_i : i 번째 데이터셋

$E(x, y) \in \left\langle \frac{\partial L}{\partial w} \Big|_{w_i} \right\rangle_{D_i}$; 해당 데이터에 대한 손실함수 기울기

↳ 가중치 초기화: $M=0, \Gamma=0.01$ (가우시안)

→ bias: conv2,4,5 + fc1,2,3 모두 1로 초기화해서 $y = w^T x + b = 1$

값이 0인 경우 $ReLU=0$ 이 되는 문제 ($ReLU$ 의 $y > 0 \rightarrow 1$, $y < 0 \rightarrow 0$)를 막음

→ 학습 초기에 수렴 가속

($w[2] = 0$)

2. batch size: 128 / epochs = 90 / lr = 0.01 (초기 70% x (plateau), $\frac{1}{10}$ 씩 감소, 3번 감소)

6. Results

7. Discussion

→ depth 가 성능 단층에 핵심